공주대학교 대학원 기계공학과 · 2026학년도 2학기

자율주행

확률론적 상태 추정 기반 · Autonomous Driving

04

4주차 — 가우시안 필터 II : EKF · UKF · 정보 필터

선형이 아닌 세계에 칼만 필터를 밀어 넣는 세 가지 방법

담당 이세진

주교재 『확률론적 로보틱스』 3.3–3.6절 (p.90~)

Q 지난주에서 이어서

3주차의 결론과 3주차가 남긴 문제

3주차의 결론

선형 가우시안이면 정확히 풀린다

칼만 필터 다섯 줄. 예측은 합성곱, 보정은 곱셈, 이득은 두 정보원의 분산 비율이었다.
등속 목표물 추적(ACC)처럼 조건이 맞는 문제에서는 이보다 나은 추정기가 없다.

남은 문제

차량은 선형이 아니다

자전거 모델의 cos θ · sin θ, 거리 측정의 √, 방위각의 atan2 — 3.2절의 조건 1·2 가 곧바로 깨진다.
비선형 함수를 통과한 가우시안은 더 이상 가우시안이 아니다.

오늘의 세 가지 대응 — 함수를 선형화(EKF) · 분포를 샘플링(UKF) · 표현을 뒤집기(정보 필터)

ROS 2 의 robot_localization 패키지가 EKF 와 UKF 두 노드를 함께 제공하는 이유가 여기 있다. 실무에서 둘 중 무엇을 고를지는 4.5절의 비교표로 판단한다.
정보 필터는 오늘 당장 쓰는 필터가 아니라 13주차 GraphSLAM · 14주차 SEIF 의 언어다 — 지금 캐노니컬 파라미터화에 익숙해질 것.

00

이번 주 학습목표

수업이 끝났을 때 할 수 있어야 하는 것

1 선형화가 왜 필요한지 설명하고, 테일러 전개에 기반한 EKF 의 야코비안 G_t, H_t 를 직접 유도한다.

2 **선형화 오차가 사후분포를 어떻게 왜곡하는지 정성적으로 설명하고, 오차 크기를 좌우하는 두 요인을 지목한다. (핵심)**

3 분산점(sigma point) 변환의 원리를 설명하고, UKF 가 EKF 보다 정확한 이유를 모멘트 관점에서 서술한다.

4 모멘트 파라미터화와 캐노니컬 파라미터화의 쌍대성을 이해하고, 정보 필터에서 측정 갱신이 덧셈이 되는 이유를 유도한다.

5 네 가지 필터(KF · EKF · UKF · EIF)의 계산 복잡도와 적용 조건을 표로 정리하고 상황에 맞게 선택한다.

선형화가 필요한 이유

4.1

비선형 함수를 통과한 가우시안은 더 이상 가우시안이 아니다. 이것이 문제의 전부다.
칼만 필터를 계속 쓰려면 "그래도 가우시안인 척" 해야 하고, 그 방법이 둘로 갈린다.

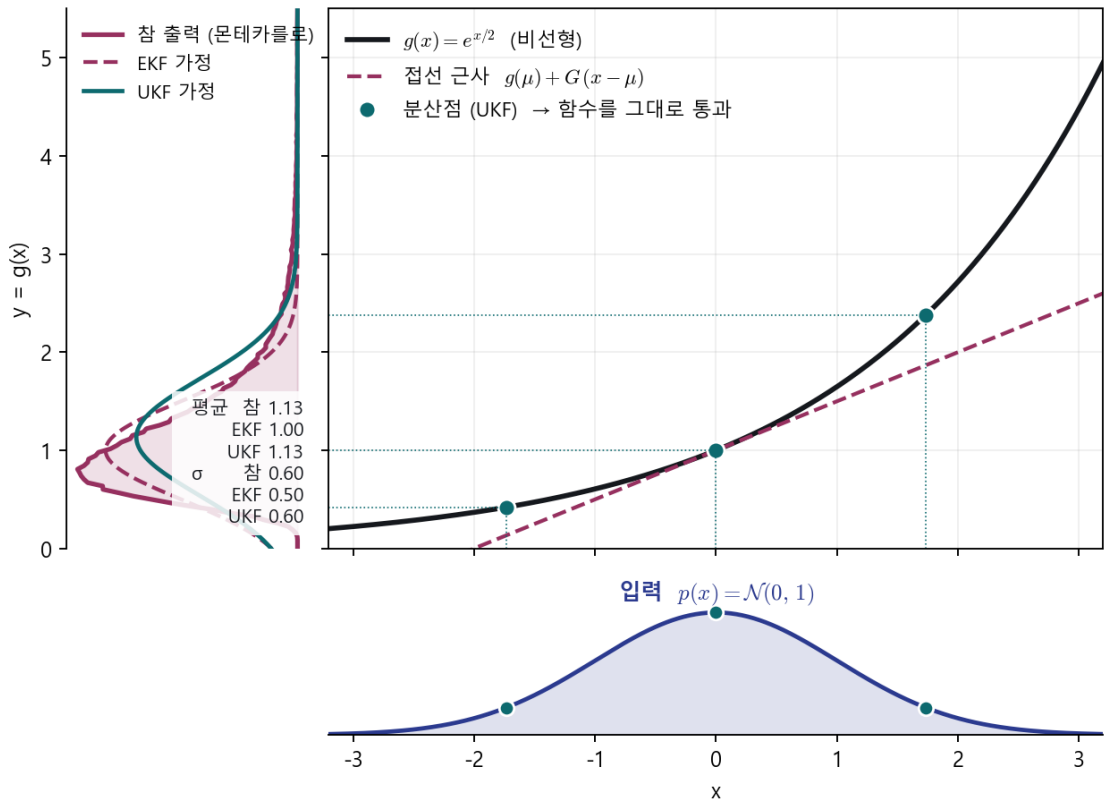
4.1

가우시안이 비선형 함수를 통과하면

식 (4.1) — 일반 비선형 시스템. g 와 h 는 더 이상 행렬이 아니다

식 (4.1)

$$x_t = g(u_t, x_{t-1}) + \varepsilon_t, \qquad z_t = h(x_t) + \delta_t$$



참 출력 — 비대칭

입력 N(0, 1) 을 g(x) = $e^{x/2}$ 에 통과시킨 참 분포는 오른쪽 꼬리가 길다. 평균 1.13, σ 0.60. 가우시안이 아니므로 (μ, Σ) 로 정확히 요약할 수 없다.

EKF 의 가정 — 접선

평균점의 접선으로 통과시키면 N(1.00, 0.50^2). 평균이 0.13 어긋나고 σ 는 17 % 작다 — 실제보다 자신만만하다(과신). 이 차이가 선형화 오차이며, 필터는 스스로 인식하지 못한 채 누적한다.

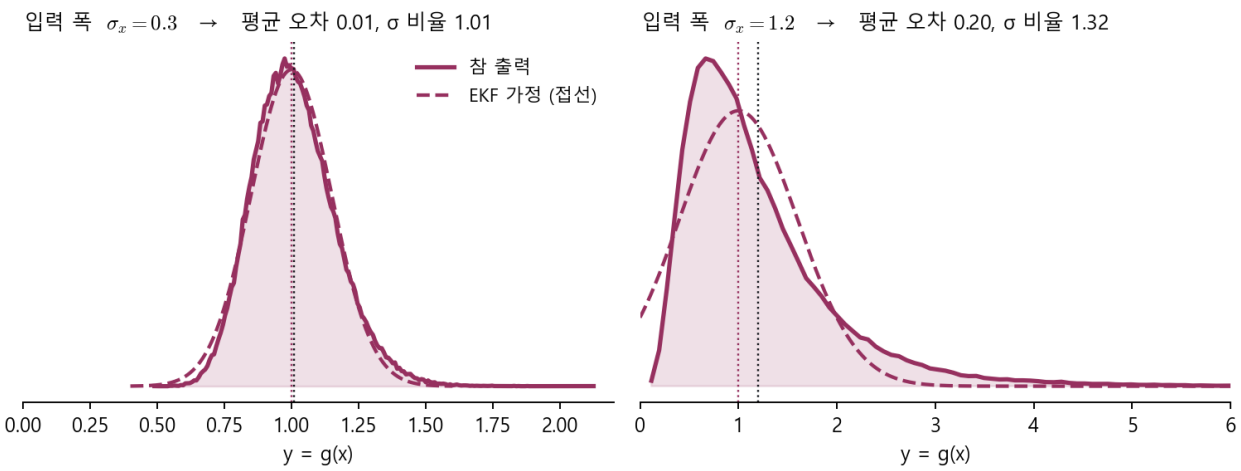
UKF 의 가정 — 분산점

점 세 개를 함수에 그대로 통과시켜 평균 1.13, σ 0.60 — 이 예에서는 참값과 일치한다. 함수가 아니라 분포를 근사한 결과다 (4.3절).

$$g(x) = e^{x/2}, \qquad \mathbb{E}[g(x)] = e^{\mu/2 + \sigma^2/8} \neq g(\mu)$$

4.1 선형화 오차를 키우는 두 요인

같은 함수, 같은 평균 — 입력의 폭만 다르게



요인 ①

함수의 국소 비선형성

곡률이 클수록 접선 근사가 나빠진다. 지수함수의 곡률, atan2 의 원점 근처, 자전거 모델의 큰 조향각.

요인 ②

사전분포의 불확실성 Σ^-

분포가 넓을수록 접선이 유효한 범위 밖까지 근사한다. σ_x 0.3 → 오차 없음, σ_x 1.2 → 평균 0.20 어긋나고 σ 32 % 과소.

둘째 요인이 실무적으로 더 중요하다 — 불확실성이 큰 상태에서 EKF 를 시작하면 발산하기 쉽다

EKF 가 전역 로컬화에 부적합한 두 번째 이유다 (첫 번째는 3주차의 단봉성). 같은 코드라도 초기 공분산을 크게 주는 순간 성격이 달라진다.

실습에서 확인 — python ekf_vs_ukf.py --sigma0 9 (초기 σ 3배, 100회): 평균 RMSE EKF 0.52 m vs UKF 0.45 m, 평균 NEES 27 vs 10 (구간 이탈 59 % vs 41 %), Cholesky 실패 9회. 필터는 그대로, 초기 불확실성만 키웠을 뿐이다.

확장형 칼만 필터 (EKF)

4.2

비선형 함수를 현재 추정치 근방에서 1차 테일러 전개하고, 나머지는 칼만 필터를 그대로 돌린다.
평균에는 원래 함수를, 공분산에는 야코비안을 쓴다 — 이 비대칭이 EKF 의 실용적 정확도를 만든다.

4.2 테일러 전개 — 접선으로 바꿔치기

식 (4.2)(4.3). 전개 기준점은 "지금 갖고 있는 가장 좋은 추정값"

식 (4.2)

$$g(u_t, x_{t-1}) \approx g(u_t, \mu_{t-1}) + G_t\,(x_{t-1} - \mu_{t-1})$$

$$G_t = \frac{\partial\, g(u_t, \mu_{t-1})}{\partial x_{t-1}} \qquad (n \times n)$$

모션 함수는 직전 사후 평균 μ_{t-1} 주위에서

식 (4.3)

$$h(x_t) \approx h(\bar{\mu}_t) + H_t\,(x_t - \bar{\mu}_t)$$

$$H_t = \frac{\partial\, h(\bar{\mu}_t)}{\partial x_t} \qquad (k \times n)$$

측정 함수는 이번 예측 평균 $\bar{\mu}_t$ 주위에서

전개 기준점을 놓치지 말 것

G_t 는 μ_{t-1} 에서, H_t 는 $\bar{\mu}_t$ 에서 평가한다 — 서로 다른 시점의 서로 다른 추정값이다. 구현에서 이 둘을 혼동하면(예: H_t 를 μ_{t-1} 에서 평가) 필터가 미묘하게 편향되며, 잡음이 큰 상황에서만 드러나기 때문에 디버깅이 매우 어렵다. 야코비안 함수의 인자 이름을 mu_bar 로 두는 습관이 사고를 막는다.

(4.2)(4.3) 을 3주차 유도에 넣으면 $A_t \to G_t$, $C_t \to H_t$ 로 바뀐 칼만 필터가 그대로 나온다

선형화된 시스템은 다시 선형 가우시안이므로 3주차의 다섯 줄이 그대로 성립한다. 다만 "정확한 사후확률"이 아니라 "선형화된 시스템의 정확한 사후확률" — 그 차이가 선형화 오차다.

4.2

다섯 줄 — 무엇이 바뀌었나

$A_t \to G_t$, $C_t \to H_t$, 그리고 평균에는 원래 함수를 그대로 쓴다

Algorithm `Extended_Kalman_filter` $(\mu_{t-1},\ \Sigma_{t-1},\ u_t,\ z_t)$

1	$\bar{\mu}_t = g(u_t, \mu_{t-1})$	← 비선형 함수 g 를 그대로 사용
2	$\bar{\Sigma}_t = G_t \Sigma_{t-1} G_t^\top + R_t$	← 공분산 전파에만 야코비안 G_t
3	$K_t = \bar{\Sigma}_t H_t^\top (H_t \bar{\Sigma}_t H_t^\top + Q_t)^{-1}$	
4	$\mu_t = \bar{\mu}_t + K_t(z_t - h(\bar{\mu}_t))$	← 혁신도 비선형 함수 h 로 계산
5	$\Sigma_t = (I - K_t H_t)\bar{\Sigma}_t$	
6	return $\mu_t,\ \Sigma_t$	

$$A_t \to G_t, \qquad C_t \to H_t, \qquad A_t\mu_{t-1} + B_t u_t \to g(u_t, \mu_{t-1}), \qquad C_t\bar{\mu}_t \to h(\bar{\mu}_t)$$

평균 계산에 야코비안 대신 원래 함수를 쓴다 — 이 마지막 점이 EKF 의 실용적 정확도를 크게 높인다. 접선은 공분산을 "옮기는" 데만 쓰고, 위치 자체는 진짜 함수로 계산하기 때문이다.

4.2

예제 — 속도 모션 모델의 야코비안

원호 운동을 하는 이동로봇 (교재 5.3절 모델을 미리 빌려온다)

$$x = (x,\ y,\ \theta)^{\mathsf{T}}, \qquad u = (v,\ \omega)^{\mathsf{T}}$$

모션 함수 g

$$g(u,\ x) = \begin{bmatrix} x - \frac{v}{\omega}\sin\theta + \frac{v}{\omega}\sin(\theta + \omega\Delta t) \\ y + \frac{v}{\omega}\cos\theta - \frac{v}{\omega}\cos(\theta + \omega\Delta t) \\ \theta + \omega\Delta t \end{bmatrix}$$

x 로 미분한 야코비안 G_t (3×3)

$$G_t = \frac{\partial g}{\partial x} = \begin{bmatrix} 1 & 0 & -\frac{v}{\omega}\cos\theta + \frac{v}{\omega}\cos(\theta + \omega\Delta t) \\ 0 & 1 & -\frac{v}{\omega}\sin\theta + \frac{v}{\omega}\sin(\theta + \omega\Delta t) \\ 0 & 0 & 1 \end{bmatrix}$$

읽는 법

1·2열은 단위행렬 — x, y 는 자기 자신에 선형으로 더해진다. 비선형성은 오직 3열, 즉 θ 에 대한 미분에만 있다. 조향이 위치에 미치는 영향이 방위각을 통해서만 들어온다는 뜻이고, 그래서 방위각 오차가 위치 오차로 자라던 1주차 현상이 여기서 다시 보인다.

실무

6주차 자전거 모델도 같은 구조다. 야코비안은 손으로 미분하거나 sympy 로 생성한다 (과제에서 sympy 허용). 수치 미분으로 검산하는 습관 — 야코비안 부호 오류는 발산으로만 드러난다.

G_t 는 (v, ω, θ) 가 바뀔 때마다 매 스텝 새로 평가하는 시변 행렬이다 — 칼만 필터의 상수 A 와 다르다.

4.2

구현 시 함정 세 가지

EKF 로컬화 과제에서 실제로 가장 많이 나오는 버그 순서대로

① ω → 0 에서 v/ω 발산

$$\omega \to 0: \quad \frac{v}{\omega}[\sin(\theta+\omega\Delta t)-\sin\theta] \;\to\; v\,\Delta t\cos\theta$$

직진에 가까울수록 v/ω 가 무한대로 간다. |ω| < 10^{-6} 이면 직진 모델로 분기하거나 위 극한값을 쓴다. 자율주행에서는 고속도로 직진이 곧 이 경우다 — 예외가 아니라 기본 상황.

② 각도 정규화

$$\mathrm{wrap}(a) \;=\; ((a+\pi) \bmod 2\pi) - \pi \;\in\; (-\pi,\, \pi]$$

혁신 $z_t - h(\mu^-_t)$ 에 각도 성분이 있으면 반드시 (−π, π] 로 감싼다. 빠뜨리면 179° 와 −179° 의 차이가 358° 로 계산되어 필터가 즉시 발산한다. UKF 에서는 dZ 와 innov 두 군데 모두.

③ 공분산의 대칭성

$$\Sigma \leftarrow \tfrac{1}{2}(\Sigma + \Sigma^{\mathsf{T}})$$

수치 오차로 Σ 가 비대칭·비양정치가 되면 서서히 망가진다 (Cholesky 실패, 음의 분산). 매 스텝 대칭화하거나 3주차의 Joseph 형식을 쓴다. 배포 코드는 둘 다 넣었다.

--nowrap 으로 ② 를 빼면: RMSE 0.32 m → 9.9 m, NEES 5 → 7,900. 두 필터 모두 즉시 발산한다 (과제 2번)

세 함정 모두 수학이 아니라 구현의 문제다 — 그래서 교재에는 없고 과제 채점표에는 있다. 배포 코드 ekf_vs_ukf.py 에는 ②(wrap) 과 ③(Joseph 형식 · 대칭화) 이 들어 있다.

무향 칼만 필터 (UKF)

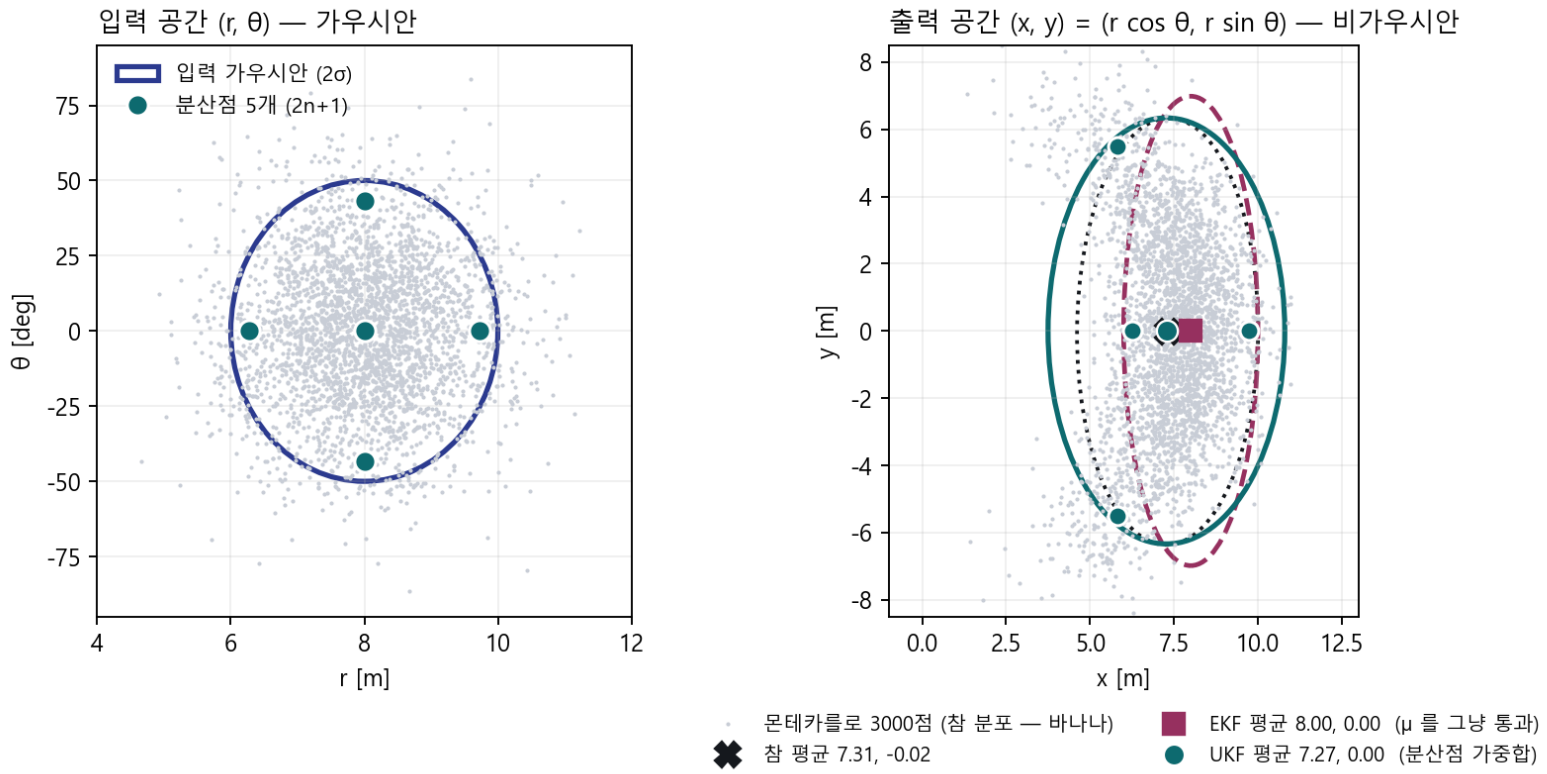
4.3

EKF 는 함수를 근사한다. UKF 는 발상을 뒤집어 분포를 근사한다.
가우시안을 대표하는 점 몇 개를 비선형 함수에 그대로 통과시키고, 나온 점들로 평균과 공분산을 다시 잰다.

4.3

핵심 아이디어 — 분산점 변환

극좌표 (r, θ) 의 가우시안을 직교좌표 (x, y) 로 옮기면



읽는 법

왼쪽: 입력 타원의 "뼈대"만 남긴 점 5개 (2n+1).

오른쪽: 점 5개가 통과한 결과의 가중 평균 7.27 은 참 평균 7.31 에 붙는다. EKF 는 μ 를 그냥 통과시켜 8.00 — 0.7 m 편향.

공분산 타원도 UKF(실선)가 참(점선)에 가깝고, EKF(파선)는 폭과 방향이 다르다.

$$\mathbb{E}[r\cos\theta] = \bar{r}\, e^{-\sigma_\theta^2/2} = 8 \times e^{-0.095} = 7.27 \neq 8$$

야코비안이 필요 없다 — 함수를 호출만 할 수 있으면 된다.

4.3

분산점 고르기 — 식 (4.4)

n 차원 가우시안 (μ, Σ) 에서 2n + 1 개의 결정론적 점

식 (4.4)

$$\mathcal{X}^{[0]} = \mu, \qquad \mathcal{X}^{[i]} = \mu + \left(\sqrt{(n+\lambda)\Sigma}\right)_i, \qquad \mathcal{X}^{[i+n]} = \mu - \left(\sqrt{(n+\lambda)\Sigma}\right)_i$$

$$\lambda = \alpha^2 (n+\kappa) - n, \qquad i = 1, \ldots, n$$

행렬 제곱근

$(\sqrt{\cdot})_i$ 는 행렬 제곱근의 i 번째 열 — 보통 Cholesky 분해 L ($LL^T = (n+\lambda)\Sigma$). Σ 가 양정치가 아니면 분해가 실패한다 → 필터가 망가졌다는 조기 경보로 쓸 수 있다 (과제 4번).

개수

$n = 4 \Rightarrow 2n + 1 = 9$ 개, $n = 1000 \Rightarrow 2001$ 개

계산량은 차원에 선형으로 는다. 입자 필터의 수천~수만 개와 비교하면 매우 적다 — 대신 가우시안이라는 가정을 얹은 대가다.

기하

평균 하나 + 각 주축 방향으로 $\pm\sqrt{(n+\lambda)}\,\sigma$ 만큼 떨어진 점 2n 개. 타원의 골격만 남긴 것이다. λ 가 음수이면 (α 가 작을 때) 점들이 평균 가까이 모인다.

점들을 무작위로 뽑지 않는다 — 결정론적이라 같은 입력에 항상 같은 출력

5주차 입자 필터와의 결정적 차이. 재현 가능하고, 개수가 적고, 가우시안을 전제한다.

4.3

가중치와 모멘트 복원 — 식 (4.5)

평균은 w_m 으로, 공분산은 w_c 로 가중합한다

$$w_m^{[0]} = \frac{\lambda}{n+\lambda}, \qquad w_c^{[0]} = \frac{\lambda}{n+\lambda} + (1-\alpha^2+\beta), \qquad w_m^{[i]} = w_c^{[i]} = \frac{1}{2(n+\lambda)}$$

$$\mu' = \sum_{i=0}^{2n} w_m^{[i]}\, g(\mathcal{X}^{[i]})$$

식 (4.5)

$$\Sigma' = \sum_{i=0}^{2n} w_c^{[i]}\, \big(g(\mathcal{X}^{[i]}) - \mu'\big)\big(g(\mathcal{X}^{[i]}) - \mu'\big)^{\mathsf{T}}$$

파라미터	전형값	역할
α	10^{-3} ~ 1	분산점이 평균에서 얼마나 멀리 퍼지는가. 작을수록 국소적 — 강한 비선형에서 먼 점이 엉뚱한 값을 내는 것을 막는다.
κ	0 또는 3 − n	보조 척도 파라미터. 고차 모멘트 정합에 관여. n + κ > 0 이어야 제곱근이 정의된다.
β	2	사전분포의 형태에 대한 지식. 가우시안이면 2 가 최적 (4차 모멘트 정합).

첫 점(평균)의 공분산 가중치에만 $(1 - \alpha^2 + \beta)$ 를 더한다 — 가우시안의 4차 모멘트를 맞추기 위한 보정

배포 코드의 기본값 $\alpha = 10^{-3}$, $\kappa = 0$, $\beta = 2$ 는 문헌의 표준값이다. 과제 4번에서 α 를 1 까지 올려 보며 무슨 일이 생기는지 본다.

4.3

EKF vs UKF — 무엇이 다른가

네 가지 축으로 비교한다

정확도

UKF 는 3차 항까지 평균을 맞춘다

가우시안 입력일 때 테일러 전개 기준 3차 항까지 평균이 정확하다. EKF 는 1차까지. 앞의 예에서 UKF 평균 1.13 = 참, EKF 1.00. 공분산은 둘 다 근사이지만 UKF 가 보통 낫다.

야코비안 불필요

함수를 호출만 할 수 있으면 된다

미분 불가능하거나 해석적 미분이 번거로운 함수 — 룩업 테이블, 타이어 모델, 시뮬레이터, 학습된 신경망 — 에도 적용된다. 실무에서 정확도보다 이 장점이 더 자주 채택 이유가 된다.

계산량

비선형 함수 2n + 1 회 + Cholesky 한 번

EKF 보다 무겁지만 야코비안 계산 비용을 아끼므로 실제 차이는 크지 않다. 4차원 실습에서 두 필터의 실행 시간 차이는 약 2배 — n 이 수백인 SLAM 에서는 이야기가 달라진다.

공통 한계

둘 다 결과를 가우시안 하나로 요약한다

분산점이 바나나 모양으로 퍼져도 마지막에는 평균과 공분산으로 접는다. 다봉 분포는 여전히 표현하지 못한다 — 2주차 세 가설, 터널 출구, 주차장 진입은 5주차가 맡는다.

선택 기준: 야코비안을 신뢰할 수 있고 비선형이 약하면 EKF, 아니면 UKF. robot_localization 의 기본 노드는 EKF, 비선형 센서 모델이 많으면 UKF 로 바꾼다.

정보 필터 — 쌍대적 표현

4.4

같은 가우시안을 (μ, Σ) 대신 $(\xi, \Omega) = (\Sigma^{-1}\mu, \Sigma^{-1})$ 로 쓴다.
표현만 바꿨을 뿐인데 보정이 덧셈이 되고 예측이 역행렬이 된다 — 비용이 자리를 바꾼다.

4.4

캐노니컬 파라미터화 — 식 (4.6)

정보행렬 Ω 와 정보벡터 ξ

식 (4.6)

$$\Omega = \Sigma^{-1} \quad \text{(정보행렬)}, \qquad \xi = \Sigma^{-1}\mu \quad \text{(정보벡터)}$$

$$p(x) = \text{const} \cdot \exp\left(-\tfrac{1}{2}\, x^{\mathsf{T}}\Omega\, x \;+\; x^{\mathsf{T}}\xi\right)$$

$$\Sigma = \Omega^{-1}, \qquad \mu = \Omega^{-1}\xi$$

이름의 뜻

Ω 는 "얼마나 아는가"를 직접 잰다

Σ 가 "얼마나 모르는가"라면 Ω = Σ⁻¹ 는 그 반대다. Ω 가 클수록 분포가 좁다. 3주차 1/σ² 덧셈이 여기서 행렬로 일반화된다. ξ = Ω μ 는 정보로 가중된 평균 — 평균을 꺼내려면 μ = Ω⁻¹ξ 로 풀어야 한다.

모멘트 폼이 못 하는 것

$$\Omega = 0 \iff \Sigma = \infty \quad \text{(완전 무지)}$$

"정보가 없음"을 표현할 수 있다. Ω = 0 은 완전 무지(무한 공분산)인데, 모멘트 폼에서는 Σ = ∞ 를 다룰 수 없다. 초기 빌리프를 정직하게 "모른다"로 두고 첫 측정부터 시작할 수 있다 — 3주차 관찰 ③ 의 근본 해법.

지수부를 전개하면 $-\tfrac{1}{2}(x-\mu)^{\mathsf{T}}\Sigma^{-1}(x-\mu) = -\tfrac{1}{2}\, x^{\mathsf{T}}\Omega x + x^{\mathsf{T}}\xi + \text{const}$ — 같은 함수, 다른 좌표.

2차항의 계수가 Ω, 1차항의 계수가 ξ. 가우시안을 곱하는 일은 이 두 계수를 더하는 일이 된다 — 다음 장.

4.4

측정 갱신이 덧셈이다 — 식 (4.7)

3주차 식 (3.5) 를 정보행렬로 다시 읽는다

식 (4.7)

$$\Sigma_t^{-1} = \bar{\Sigma}_t^{-1} + C_t^{\mathsf{T}} Q_t^{-1} C_t \quad \Longleftrightarrow \quad \Omega_t = \bar{\Omega}_t + C_t^{\mathsf{T}} Q_t^{-1} C_t$$

$$\Omega_t = \bar{\Omega}_t + \sum_{k=1}^{K} H_k^{\mathsf{T}} Q_k^{-1} H_k \qquad \text{(센서 } K\text{개, 순서 무관)}$$

①

다중 센서 융합이 자명하다

서로 독립인 K 개의 측정은 K 개의 항을 그냥 더한다. 순서도 상관없다. 레이더·카메라·GNSS 를 도착 순서대로 더하면 끝 — 비동기 센서 스택의 자연스러운 표현.

②

측정 차원이 커도 싸다

역행렬 크기가 측정 차원 k 에 의존하지 않는다 — 3주차 계산 복잡도 논의의 반대편. LiDAR 스캔 전체(k ≫ n)를 한 번에 넣을 때 유리하다.

③

13주차 GraphSLAM 의 언어

GraphSLAM 은 모든 측정을 정보행렬에 더해 놓고 마지막에 한 번 푼다. "측정 = 정보를 더하는 것"이라는 관점이 그 출발점이다.

2주차 3행의 곱셈이 로그 공간에서 덧셈이 된 것뿐이다

가우시안의 곱 = 지수부의 합 = (Ω, ξ) 의 합. 정규화 상수 η 는 const 에 흡수된다.

4.4

EIF 알고리즘 — 다섯 줄, 비용이 자리를 바꾼다

확장형 정보 필터. 4행이 (4.7), 나머지는 표현 변환

Algorithm `Extended_information_filter` $(\xi_{t-1},\ \Omega_{t-1},\ u_t,\ z_t)$

1	$\mu_{t-1} = \Omega_{t-1}^{-1}\,\xi_{t-1}$	← g 를 평가하려면 μ 복원 (역행렬 1회)
2	$\bar{\Omega}_t = \left(G_t\,\Omega_{t-1}^{-1}\,G_t^{\mathsf{T}} + R_t\right)^{-1}$	← 역행렬 두 번 — 비싸다
3	$\bar{\xi}_t = \bar{\Omega}_t\ g(u_t,\ \mu_{t-1})$	
4	$\Omega_t = \bar{\Omega}_t + H_t^{\mathsf{T}} Q_t^{-1} H_t$	← 덧셈 한 줄
5	$\xi_t = \bar{\xi}_t + H_t^{\mathsf{T}} Q_t^{-1}\left[z_t - h(\bar{\mu}_t) + H_t\bar{\mu}_t\right]$	← 대괄호 안 = 선형화된 "가상 측정"
6	return $\xi_t,\ \Omega_t$	

5행의 $z_t - h(\bar{\mu}_t) + H_t\bar{\mu}_t$ 는 비선형 h 를 $\bar{\mu}_t$ 에서 선형화했을 때 "만약 측정이 선형 $H_t x$ 였다면 얻었을 값" — 이것을 (4.7) 과 짝이 되는 정보벡터 갱신에 넣은 것이다.

보정은 덧셈 두 줄, 예측은 역행렬 두 번 — EKF 와 정확히 반대의 비용 구조.

4.4 대가 — 예측이 비싸다. 그런데 왜 배우는가

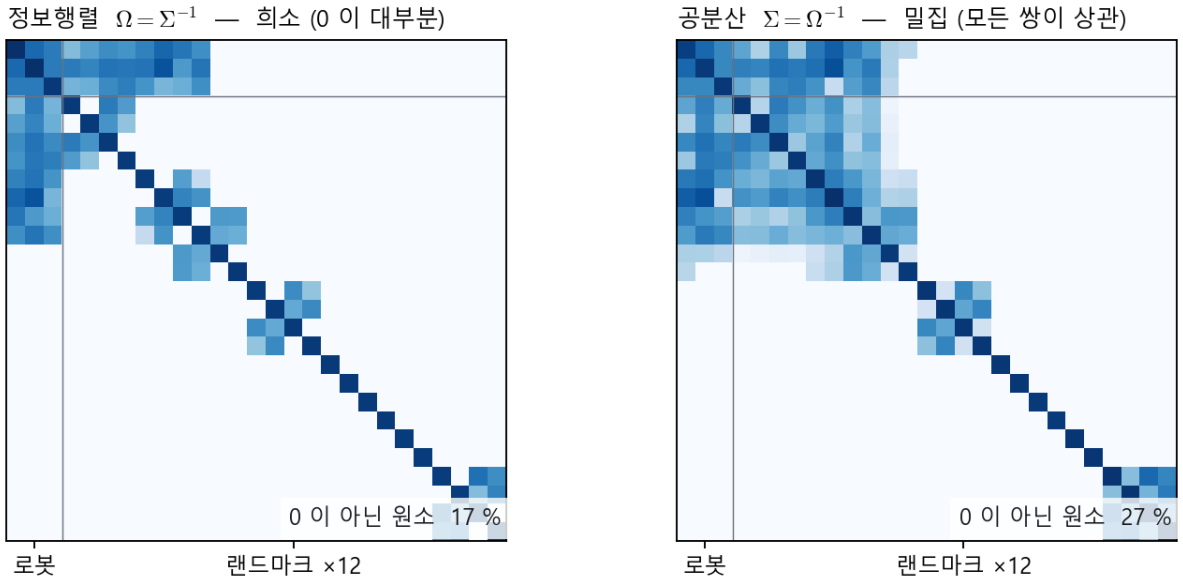
어느 쪽도 공짜가 아니다 · SLAM 의 정보행렬은 희소하다

대가

예측 단계에 n×n 역행렬이 두 번

EKF 는 예측이 싸고 보정이 비쌌다. 정보 필터는 정확히 반대다. 표현을 바꾸면 비용이 자리를 옮길 뿐 사라지지 않는다.

그래서 "지금 쓰는 필터"로서의 EIF 는 드물다. 배우는 이유는 오른쪽 그림에 있다.



SLAM 의 정보행렬은 희소하다

로봇은 근처 랜드마크만 관측하므로 Ω 는 로봇–랜드마크 몇 개의 링크와 대각 블록뿐이다. 반면 Σ = Ω⁻¹ 은 모든 쌍이 상관되어 밀집한다. 희소한 Ω 만 유지하면 예측 단계의 역행렬도 국소 연산이 되어 비용이 O(1) 로 떨어진다 — 그것이 14주차 SEIF 의 아이디어다.

정보 필터는 "지금 쓰는 필터"가 아니라 SEIF · GraphSLAM 을 읽기 위한 언어다.

네 필터 비교와 실습

4.5

KF · EKF · UKF · EIF 를 한 표에 놓고, 비선형 관측을 갖는 추적 문제에서 EKF 와 UKF 를 실제로 겨룬다.
RMSE 만 보면 차이가 없다 — 차이는 "자기 오차를 얼마나 정직하게 보고하는가"에서 난다.

4.5

네 필터 비교

표현 · 비선형 처리 · 비용 · 이 강의에서의 자리

	KF	EKF	UKF	EIF
표현	μ, Σ	μ, Σ	μ, Σ	ξ, Ω
비선형 처리	불가	1차 테일러 (야코비안)	분산점 (3차 정확)	1차 테일러
야코비안	불필요	**필요**	불필요	**필요**
예측 비용	싸다	싸다	중간 (함수 2n+1 회)	**비싸다 (역행렬 2회)**
보정 비용	O(k^2.4) 역행렬	O(k^2.4) 역행렬	O(k^2.4) 역행렬	**싸다 (덧셈)**
다봉 표현	**모두 불가능 — 5주차 비모수 필터가 필요한 이유**			
이 강의에서	3주	9주 로컬화 · 12주 EKF SLAM	9주 UKF 로컬화	14주 SEIF

넷 다 단봉 가우시안이라는 제약을 공유한다

선택 기준은 (1) 비선형의 세기, (2) 야코비안을 구할 수 있는가, (3) 측정 차원 k 와 스테이트 차원 n 중 어느 쪽이 큰가.

4.5 실습 — 극좌표 관측을 갖는 2D 추적

스테이트는 선형(등속), 측정만 비선형(거리·방위각)

$$x = (p_x,\ p_y,\ v_x,\ v_y)^{\mathsf{T}}, \qquad z = (r,\ b)^{\mathsf{T}}$$

관측 함수 h — 원점의 센서

$$h(x) = \begin{bmatrix} \sqrt{p_x^2 + p_y^2} \\ \operatorname{atan2}(p_y,\ p_x) \end{bmatrix} = \begin{bmatrix} r \\ b \end{bmatrix}$$

야코비안 H (2×4) — EKF 에만 필요

$$H = \frac{\partial h}{\partial x} = \begin{bmatrix} p_x/r & p_y/r & 0 & 0 \\ -p_y/r^2 & p_x/r^2 & 0 & 0 \end{bmatrix}$$

전이 — 등속 모델, 선형

$$A = \begin{bmatrix} 1 & 0 & \Delta t & 0 \\ 0 & 1 & 0 & \Delta t \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 1 \end{bmatrix} \quad (= G_t,\ \text{선형})$$

실험 설계

목표물이 원점(센서)을 0.5 m 옆으로 스쳐 지난다 (t = 10 s). 이때 방위각 b = atan2(p_Y, p_x) 의 비선형성이 극단적으로 커진다.
σ_r = 0.5 m, σ_b = 4°, Δt = 0.1 s, 20 s. 초기 σ = 3 m / 1 m/s. 100회 몬테카를로.

전이가 선형(G = A)이라 두 필터의 예측은 같다 — 차이는 오직 보정, 즉 h 를 어떻게 근사하는가에서만 난다

실험 변수를 하나로 고정한 것이다. 6주차 이후 모션까지 비선형이 되면 예측 단계에도 같은 논의가 붙는다.

4.5 코드 — 분산점 하나, 보정 하나

ukf_correct 에는 야코비안 H 가 어디에도 없다

```
def sigma_points(mu, Sig, alpha=1e-3, kappa=0.0, beta=2.0):
    n = len(mu)
    lam = alpha**2 * (n + kappa) - n
    S = np.linalg.cholesky((n + lam) * Sig)     # 행렬 제곱근
    X = np.vstack([mu, mu + S.T, mu - S.T])     # (2n+1, n)
    wm = np.full(2*n+1, 1/(2*(n+lam))); wm[0] = lam/(n+lam)
    wc = wm.copy();  wc[0] += 1 - alpha**2 + beta
    return X, wm, wc

def ukf_correct(mu_b, Sig_b, z):
    X, wm, wc = sigma_points(mu_b, Sig_b)
    Z = np.array([h(x) for x in X])            # h 를 그대로 통과
    z_hat = wm @ Z
    dZ = Z - z_hat;  dZ[:, 1] = wrap(dZ[:, 1])
    dX = X - mu_b
    S   = (wc[:,None,None] * np.einsum('ki,kj->kij', dZ, dZ)).sum(0) + Q
    Cxz = (wc[:,None,None] * np.einsum('ki,kj->kij', dX, dZ)).sum(0)
    K = Cxz @ np.linalg.inv(S)                 # 이득 = 교차공분산 / 혁신공분산
    innov = z - z_hat;  innov[1] = wrap(innov[1])
    return mu_b + K @ innov, Sig_b - K @ S @ K.T
```

sigma_points

Cholesky 로 $\sqrt{((n+\lambda)\Sigma)}$ 를 얻고 열을 ± 로 붙여 2n+1 개. 가중치 w_m, w_c 도 함께 돌려준다.

ukf_correct

h 를 9번 호출 → 예측 측정 $\hat{z}$, 혁신공분산 S, 교차공분산 C_{xz} 를 가중합으로. 이득 $K = C_{xz} S^{-1}$ 은 칼만 필터 3행의 $\Sigma^- C^T (C\Sigma^- C^T + Q)^{-1}$ 과 같은 꼴이다.

wrap

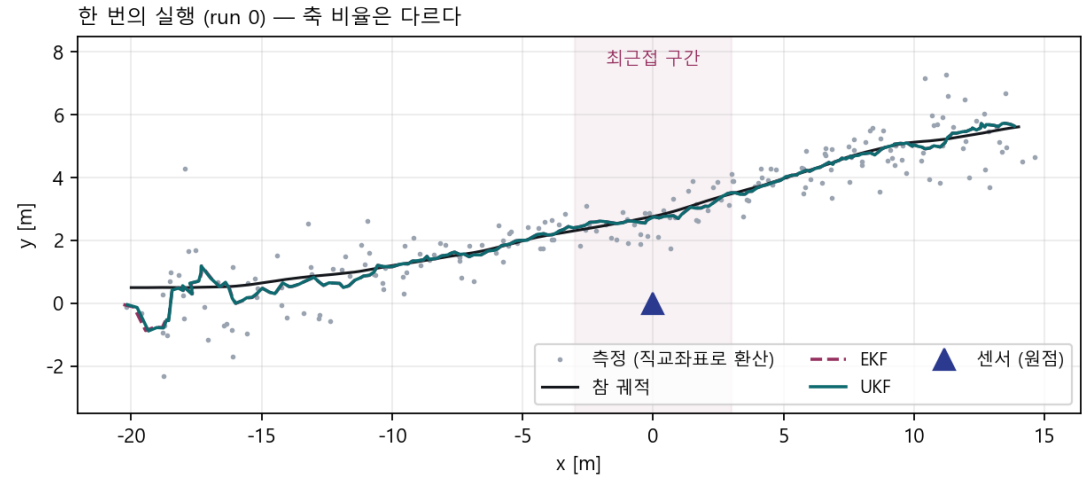
각도 차이는 dZ 와 innov 두 군데 모두 감싼다. 한 군데만 하면 S 가 틀린다.

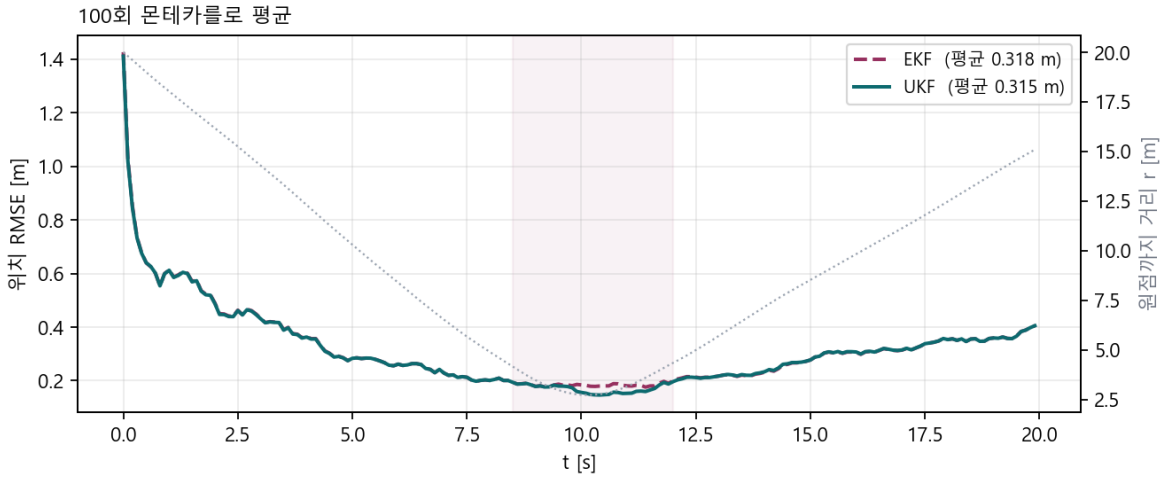
ekf_vs_ukf.py 배포. `python ekf_vs_ukf.py [--sigma0 k] [--alpha a] [--nowrap] [--runs N]`

4.5

실행 결과 — RMSE 는 같다

python ekf_vs_ukf.py (100회 몬테카를로)





0.318 / 0.315 m

EKF / UKF 의 20 s 평균 위치 RMSE. 1 % 차이 — 사실상 같다. 궤적도 겹쳐 보인다.

0.184 / 0.156 m

t = 10 s (최근접) 순간의 RMSE. 비선형이 가장 심한 구간에서만 UKF 가 15 % 낫다.

그렇다면 무엇이 다른가

추정치만 보면 두 필터를 구별할 수 없다

평균 μ 는 거의 같다. 차이는 필터가 함께 내놓는 공분산 Σ — "내 오차가 이 정도일 것"이라는 자기 보고 — 의 정직성에서 난다. 그것을 재는 도구가 NEES 다. 다음 장.

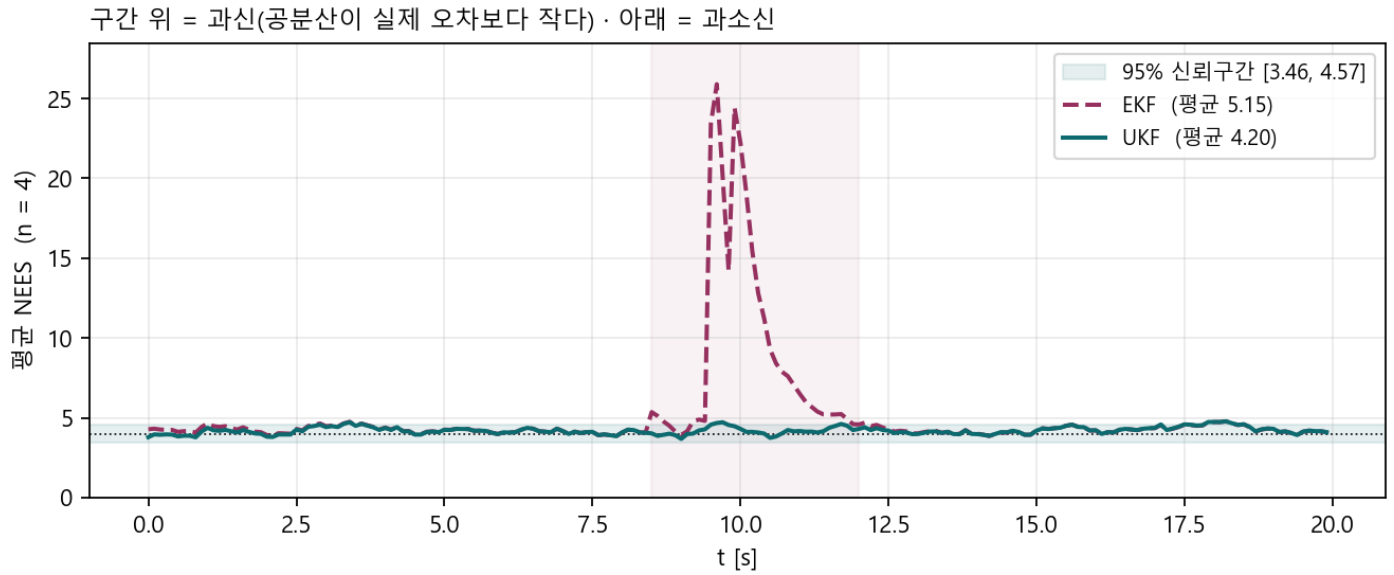
4.5

NEES — 필터가 자기 오차를 정직하게 보고하는가

정규화 추정 오차 제곱 (Normalized Estimation Error Squared) · 일관성 검정

$$\epsilon_t = (x_t - \mu_t)^\top \Sigma_t^{-1} (x_t - \mu_t), \qquad \mathbb{E}[\epsilon_t] = n$$

$$N\bar{\epsilon}_t \sim \chi^2(Nn) \quad \Rightarrow \quad N=100,\ n=4:\ \bar{\epsilon}_t \in [3.46,\ 4.57]\ (95\ \%)$$



EKF 의 과신

최근접 구간에서 NEES 26

실제 오차가 자기 공분산이 말하는 것보다 √6 ≈ 2.5 배 크다. 선형화 오차는 공분산에 나타나지 않는다 — 필터는 틀린 채로 확신한다. 구간 이탈 22.5 %.

UKF

전 구간 신뢰구간 안 (평균 4.20, 이탈 7 %). 같은 RMSE 를 내면서 자기 오차를 정직하게 보고한다.

과신은 오차보다 위험하다 — 작은 공분산을 믿고 행동하는 순간 사고가 난다 (14주차 무결성).

HW

과제 3 — 6주차 수업 전까지

ekf_vs_ukf.py 를 수정해 실험하고, 보고서(4쪽 이내)와 코드 저장소 링크를 제출한다

기초 1. 배포 코드를 실행해 EKF 와 UKF 를 같은 데이터에 돌리고 RMSE 를 비교하라. 시드를 바꿔 3회 반복하고 평균·표준편차를 표로 정리하라.

기초 2. wrap 함수를 제거(--nowrap)하면 어떤 일이 일어나는가? 첫 발산이 시작되는 스텝을 찾아 그 순간의 혁신 값과 함께 이유를 서술하라.

응용 3. 초기 공분산 Σ_0 를 10배, 100배 키우며(--sigma0) 두 필터의 발산 여부와 NEES 를 관찰하라. 4.1절의 "두 번째 요인"이 확인되는가?

응용 4. UKF 의 α 를 10^{-3} 에서 1 까지 바꾸며(--alpha) 성능 변화를 측정하라. Cholesky 분해가 실패하는 경우가 있는가? 있다면 언제, 왜인가?

심화 5. 두 필터의 NEES 를 계산하고 χ^2 신뢰구간과 비교해 일관성(consistency)을 검정하라. 어느 필터가 자신의 오차를 더 정직하게 보고하는가? 최근접 구간만 따로 분석하라.

심화 6. (4.7) 의 정보 폼 측정 갱신을 유도하고, 서로 독립인 두 측정을 순서를 바꿔 반영해도 결과가 같음을 증명하라. EKF 에서는 왜 이것이 자명하지 않은가?

보고서에는 그래프마다 해석을 붙일 것. 6번은 손으로 써도 좋다. EKF 로컬화(9주차)에서 이 코드를 확장하므로 저장소는 계속 유지한다.

END

오늘의 결론 · 다음 주 예고

EKF 는 함수를 선형화하고, UKF 는 분포를 샘플링하며, 정보 필터는 표현을 뒤집는다

셋 다 3주차의 다섯 줄 위에 서 있다. $A_t \to G_t$, $C_t \to H_t$, 또는 $(\mu, \Sigma) \to (\xi, \Omega)$.

선형화 오차 = 함수의 곡률 × 사전 불확실성. EKF 의 과신은 공분산에 나타나지 않는다

RMSE 가 같아도 NEES 는 다르다. 필터가 내놓는 공분산을 믿을 수 있는지가 실무의 질문이다.

셋 다 단봉 가우시안이라는 근본 제약은 공유한다

"A 아니면 B" 를 담지 못한다. 이 제약을 정면으로 걷어내는 것이 5주차다.

5주차 — 비모수 필터 : 가우시안을 버린다

방법	아이디어	장점	단점
히스토그램 필터	스테이트 공간을 격자로 이산화 — 2주차 실습의 일반화	임의 분포 · 다봉 표현	차원의 저주 (격자 수가 지수적)
입자 필터	샘플 집합으로 분포를 표현, 가중치로 보정 (중요도 샘플링)	임의 분포 · 비선형 그대로 · 구현 쉬움	입자 고갈 · 고차원에서 비효율

사전 통독: 교재 4.1–4.4절. 특히 중요도 샘플링(importance sampling)의 논리 — 원하는 분포에서 직접 뽑을 수 없을 때 다른 분포에서 뽑고 가중치로 보정한다 — 를 미리 이해해 올 것. 입자 필터는 10주차 MCL 과 15주차 FastSLAM 의 기반이다. 과제 3 은 6주차 수업 전까지.